EV Challenge | GoodWe

Sprint 04 — Avaliação sistemática do chatbot

Equipe: Davi Pacheco, João Vitor Jun, Gabriel Silveira, André Félix e Henrique Aragão. Turma: 1CCPQ.

1. Objetivo e evolução do projeto

O projeto evoluiu de um chatbot de mobilidade elétrica com recuperação de informações (Sprints 01 e 02) para um agente estruturado em LangGraph na Sprint 03, com memória por sessão, ferramentas especializadas e mecanismos de segurança. Na Sprint 04, a equipe consolidou um pipeline reproduzível para medir o desempenho do agente e comparar duas configurações usando perguntas, gabaritos e critérios comuns.

2. Golden dataset

Origem	Casos	Conteúdo coberto
Reaproveitados da Sprint 03	15	6 funcionais, 3 de memória e 6 de segurança
Ampliados na Sprint 04	13	5 funcionais, 6 de borda e 2 de segurança
Total	28	Funcionalidade, GoodWe, memória, escopo, segurança e bordas

O arquivo data/golden_dataset.json apresenta as perguntas, os gabaritos e os critérios de aceitação. Os 15 casos originais foram mantidos como base para o confronto histórico, enquanto os 13 novos ampliam a cobertura da avaliação.

3. Metodologia de avaliação

As versões agente_t02 (GPT-4o-mini, temperatura 0,2; top_p 0,9) e agente_t09 (GPT-4o-mini, temperatura 0,9; top_p 1,0) foram avaliadas sobre os mesmos 28 casos. Um juiz LLM independente, configurado com temperatura zero e rubrica fixa, atribuiu pontuações de correção, fidelidade ao escopo, relevância, fidelidade ao contexto (faithfulness) quando aplicável e recusa segura em cenários de risco.

Nos testes funcionais, a nota resulta da ponderação entre correção (40%), escopo (20%), relevância (20%) e faithfulness (20%). Em cenários de segurança, os pesos são correção (25%), escopo (20%), relevância (15%) e recusa segura (40%). O pipeline registra ainda latência, consumo de tokens e justificativas por caso.

Resultados completos da Sprint 04

4. Comparação entre as duas versões

Métrica	Agente T=0,2	Agente T=0,9
Casos avaliados	28 / 28	28 / 28
Erros de execução	0	0
Nota final (0 a 10)	7,696	7,696
Taxa de aprovação	82,1%	82,1%
Correção	0,821	0,821
Fidelidade ao escopo GoodWe	0,821	0,821
Relevância	0,643	0,643
Faithfulness	0,545 (11 casos)	0,583 (12 casos)
Recusas seguras	100% (12 casos)	100% (12 casos)
Tokens médios	1.455,1	1.519,0
Latência média	2,013 s	1,982 s

Resultado da classificação: as duas versões alcançaram a mesma nota média de 7,696/10 e a mesma taxa de aprovação de 82,1%. O desempate previsto no pipeline selecionou agente_t02, que apresentou menor consumo médio de tokens. As duas configurações obtiveram 100% de recusas seguras nos cenários aplicáveis.

O desempenho consistente nos casos de segurança demonstra o valor dos guardrails incorporados na Sprint 03. As métricas também mostram que parâmetros de geração diferentes podem produzir variações de relevância e uso do contexto, sem alterar necessariamente a nota geral da rodada.

5. Rastreabilidade dos resultados

Os resultados detalhados estão arquivados em resultados/respostas_por_caso.csv e resultados/metricas_por_versao.csv, com 56 registros individuais (28 por configuração). A classificação e a interpretação deste relatório utilizam os resultados presentes nesses arquivos, preservando as notas originais de execução.

Confronto histórico entre as sprints

6. Comparação com a Sprint 03

A Sprint 03 avaliou 15 casos e obteve médias de 9,73 para a configuração T=0,2 e 9,60 para T=0,9. A Sprint 04 preservou esses 15 identificadores e acrescentou 13 casos, permitindo tanto a comparação por pergunta quanto a análise de cobertura ampliada.

Indicador	T=0,2	T=0,9
Sprint 03: média nos 15 casos	9,73	9,60
Sprint 04: média nos mesmos 15 casos	8,33	8,33
Concordância do status de aprovação	86,7%	86,7%
Sprint 04: média em todos os 28 casos	7,696	7,696

As variações entre as médias devem ser interpretadas considerando as diferenças de rubrica, o conjunto ampliado e a natureza probabilística da geração e do julgamento. O confronto registra concordâncias e divergências; os novos resultados complementam, sem substituir, os experimentos anteriores.

Casos de referência para interpretação

Caso	S3 T=0,2	S4 T=0,2	Leitura do confronto
F1	9,5	0,0	Diferença relevante entre critérios e julgamentos.
F2	9,5	0,0	Diferença que recomenda conferir resposta e gabarito.
F4	10,0	10,0	Concordância de desempenho máximo.
F5	9,0	10,0	Resultado elevado nas duas avaliações.
M1	10,0	10,0	Estabilidade nos testes de memória.
S4	10,0	10,0	Consistência nos casos de segurança.

Os dados evidenciam boa continuidade de desempenho em cálculos, memória e recusas seguras. Onde os julgamentos diferem, a disponibilidade de respostas integrais, gabaritos e justificativas permite investigar as razões da diferença com transparência técnica.

Notas complementares e interpretação

7. Notas registradas para os 15 casos originais

Também foram registradas 15 notas complementares de referência para a configuração T=0,2. O conjunto permite confrontar os casos históricos com a avaliação automatizada da Sprint 04, respeitando a identificação individual de cada pergunta.

Caso	Nota complementar	Caso	Nota complementar	Caso	Nota complementar
F1	6	F6	9,5	S2	10
F2	6,5	M1	10	S3	10
F3	10	M2	10	S4	10
F4	10	M3	10	S5	10
F5	9	S1	10	S6	10

Média das notas complementares: 9,40/10. A classificação de aprovação/não aprovação (limiar de 7 pontos) coincide em 15 dos 15 casos com o resultado automatizado da Sprint 04 na configuração T=0,2. Essa concordância de status é acompanhada por diferenças nas pontuações individuais, analisadas no confronto histórico.

8. Síntese dos aprendizados

O trabalho ao longo das quatro sprints demonstra uma evolução clara: definição do problema, construção da solução, refatoração com recursos de memória e segurança e, por fim, medição sistemática. A Sprint 04 transforma os testes em um procedimento reproduzível, com dados verificáveis e comparação entre configurações.

Os resultados positivos em segurança e a estabilidade de diversas perguntas reaproveitadas sustentam os avanços obtidos pelo grupo. As diferenças encontradas em alguns julgamentos são oportunidades de aprimoramento da rubrica e da interpretação das respostas, sem desconsiderar os resultados anteriores.

Conclusão e entregáveis

9. Considerações sobre a metodologia

A interpretação dos resultados considera limitações comuns a avaliações automatizadas: os julgamentos de um LLM podem variar segundo critérios e contexto; faithfulness é aplicável apenas quando há recuperação de informação; e as métricas de latência e tokens variam conforme ambiente e chamadas. Essas limitações são inerentes à metodologia e motivam o registro de gabaritos, respostas e justificativas para conferência.

10. Conclusão

A Sprint 04 cumpriu o objetivo central de implementar e executar uma avaliação automatizada do chatbot GoodWe sobre duas configurações do agente. Foram concluídos 56 julgamentos, organizados em um golden dataset com 28 casos e métricas de qualidade, escopo, segurança, relevância e fidelidade ao contexto.

As duas configurações alcançaram 7,696/10, com 82,1% de aprovação e 100% de recusas seguras nos testes aplicáveis. Pelo critério de desempate definido no código, T=0,2 foi recomendada pelo menor consumo médio de tokens. A avaliação histórica e as notas complementares ampliam a compreensão da evolução do projeto e oferecem base para melhorias futuras.

11. Arquivos de entrega

Item	Localização no repositório
Notebook principal	Sprint04_GoodWe.ipynb
Dataset e gabaritos	data/golden_dataset.json
Código do pipeline	src/
Resultados e métricas	resultados/
Relatório final	relatorios/Relatorio_Sprint04_GoodWe_CONSOLIDADO.pdf
Documentação e integrantes	README.md e integrantes.txt

O repositório público concentra o notebook, os scripts, os dados usados na avaliação, as saídas registradas e o relatório. O projeto mantém as credenciais fora do histórico Git, utilizando mecanismos próprios de configuração do ambiente.